

경력

한국전자기술연구원 — AX 연구본부 위촉연구원

2026.02 - 현재

산업부 소관 전문생산기술연구소 · 범용 MLOps 플랫폼 담당 · 자체호스팅

- **온프레미스 MLOps 플랫폼 설계·구축 주도.** 폐쇄망에서도 동작하도록 외부 클라우드·SaaS 없이 전 구성요소를 자체호스팅. 학습·실험추적·레지스트리·CI/CD·관측을 단일 docker-compose 스택으로 묶고, 인프라팀이 운영하는 Triton compose와는 external network로 브릿지. 모니터링은 Prometheus·Grafana 15초 주기 상시 수집, 드리프트 탐지는 Evidently PoC. 외부 수령 모델은 MLflow Registry 생애주기 태그로 함께 관리
- **GPU 1대에 서로 다른 모델 10종 동시 서빙.** 3D U-Net(공간 격자 입력)과 PINN(가변 길이 좌표 입력)처럼 입출력 구조가 다른 모델을 배치 전략 분리(U-Net: dynamic batching, PINN: 개별 배치)로 L40S 1대 Triton에 통합. PINN은 좌표 100개 지점 단일 요청에 22-32ms. 고정 shape으로 export되던 ONNX 3종은 가변 입력을 받도록 직접 패치해 온보딩
- **CI 디버깅과 배포 체인 구축 — checkout 14분 → 4초.** Gitea Actions가 checkout에서 멈추던 원인을 단계별 로그로 좁혀 인증 처리 방식을 교체. 이후 ONNX 검증 → Triton 배포 → READY 폴링 → 레지스트리 메타 갱신을 한 체인으로 연결. 외부 수령 모델의 입출력 계약을 배포 전 Triton 실서빙 메타데이터와 대조해 불일치 시 차단하는 게이트도 설계·구현(5종 케이스 검증, 로컬 작업본)
- **이미지 분류 MLOps 레일 — 부풀려진 지표를 게이트로 걸러냄.** 카탈로그·라벨 검증·학습·품질 게이트·ONNX 내보내기를 직접 구현하고, 실데이터는 국가교통정보센터 공개 OpenAPI로 확보(사람 라벨링 0건). 직접 등록해 서빙하던 모델의 정확도가 데이터 누수로 부풀려진 것을 규명하고 카메라 그룹 단위로 재분할해 재측정하니 게이트가 승격을 차단 — 원인 3건을 고쳐 재등록·재배포

삼성SDI — Data Intelligence 그룹 데이터 엔지니어 인턴

2025.06 - 2025.08

- **완전 인터넷 차단 폐쇄망에서 특허 검색 RAG 챗봇 “SPA” 구축.** 외부 API 없이 사내 서버에 올린 Qwen2.5-72B(Ollama, 멘토와 공동 구성) 위에 MiniLM 임베딩과 LangChain, FAISS로 검색·분기·UI를 구현
- 대화 맥락과 직전 검색 선택지를 유지해 후속 질문에서 자동 재검색하는 멀티턴 구성. Streamlit + Docker로 배포해 임원 대상 PoC 시연
- **수치 경로 분리.** 통계·집계 질의는 키워드로 감지해 차트를 원본 DataFrame 집계로 직접 생성 — 수치를 LLM이 만들지 않도록 설계

프로젝트 · 연구

POSTECH 인공지능대학원 연구실 — 연구 협업

2026.07 - 현재

롱폼 할루시네이션 · selective generation · LLM 에이전트 — 모르는 것을 모른다고 답하게 만드는 문제

- **THREAD(NAACL 2025 Main) 재현과 결합 규명.** 공개 코드로 재현이 안 되던 원인을 결합 6건으로 특정하고, 그중 3건(비명시적 데이터 출처 선택, 토큰화 오염, 변수 미초기화)을 수정해 DataCommons QA 140문항 정확도를 **62.1에서 논문 보고치(67.9)를 넘는 68.6까지 복원**. 실패 메시지가 관측값과 형식이 같아 에러가 데이터로 보이는 현상 트레이스로 확인
- 논문에 없는 비용까지 채서 재귀 방식의 프롬프트 토큰 소모가 **343배**임을 확인, 정확도 향상의 대가를 수치로 제시. 자체 벤치마크에서는 라벨 익명화로 사전지식 누출을 차단한 대조군을 구성해, 익명화 후 재귀의 순 우위가 오히려 커짐을 확인

JisangFolio — AI 인터랙티브 포트폴리오 (개인 프로젝트 · 라이브 운영 중)

2025.08 - 현재

- Groq + Qwen3.6-27B 위에 이력서 기반 1인칭 AI 면접 챗봇을 구축하고 MCP 서버 자체 구현, 한/영 전환 지원. LLM 라우터가 질의 유형에 따라 집계(pandas 코드 생성·실행)와 하이브리드 검색(FAISS + BM25 RRF)으로 분기하고, 지식그래프 서브그래프로 질문별 근거를 주입
- 클라우드 벤더 공식 MLOps 문서를 코퍼스로 한 Agentic RAG 데모 추가 구축. 검색 → 관련성 평가 → 쿼리 재작성 → 근거 자기점검으로 이어지는 자기교정 루프를 구현하고, 에이전트 판단 단계와 출처 인용을 화면에 그대로 노출
- **회귀 평가 체계 구축.** 직접 만든 골든셋 20건 자동 실행, 최신 **17/20**. 규칙 기반 채점을 통과 조건으로, 자기채점 편향을 피해 심사는 별도 모델에 맡김. 골든셋은 벤치마크가 아닌 회귀 게이트로 쓰며, 가드레일·옵저버빌리티는 pytest + GitHub Actions로 자동 검증

학력 · 논문

University of Illinois Urbana-Champaign — B.S., Information Science + Data Science

편입 · 2025.12 졸업

GPA 3.89 / 4.0 · CS277 Algorithms and Data Structures for Data Science, IS327 Machine Learning | 편입 전 Univ. of Washington Pre-Science, GPA 3.76 · Dean's List

“Effect of Tai Chi Practice on … Perturbations While Standing in Older Adults” — *Applied Sciences* (SCIE), 2025.07

공저

압력중심(CoP) 신호처리 파이프라인 설계·구현 담당. Butterworth 6Hz 센서 노이즈 필터링, Rambling/Trembling 분해, FFT 대역 적분(NumPy/SciPy)

기술 스택

MLOps · 서빙 NVIDIA Triton Inference Server, MLflow(Tracking · Registry · 거버넌스), ONNX(변환 · 검증 · shape 패치), Docker / Compose, Gitea · GitHub Actions(CI/CD) · pytest, Prometheus, Grafana, MiniIO, 온프레미스 자체호스팅(폐쇄망 대응 설계), GPU 서빙(L40S)**AI · LLM · LLMops** RAG, 지식그래프 검색, 하이브리드 검색(BM25 + dense · RRF), LangChain, FAISS, Ollama(LLM 자체 서빙), LLM 라우팅, LLM-as-judge 회귀 평가, 가드레일 · 프롬프트 인젝션 방어, LLM 옵저버빌리티, MCP**DATA · 언어** Python(고급), SQL, R, Pandas, NumPy, SciPy, scikit-learn, PyTorch(학습 운영), 시계열 · 신호처리(Butterworth, FFT), Streamlit | 기초 경험 NGSI-LD, Evidently(드리프트 PoC), VLM 서빙(Qwen2.5-VL) | 환경 Linux, WSL2, Git / Gitea