

클라우드를 못 쓰는 폐쇄망에서 모델을 서빙 가능한 상태로 만들고 운영합니다. KETI에서는 특정 모델 전용이 아니라 다음 모델도 받을 수 있는 MLOps 플랫폼을 주도해 구축했고, 입출력 구조가 전혀 다른 외부팀 모델까지 같은 Triton에 올렸습니다. 그전 삼성SDI 인턴 때는 인터넷이 끊긴 사업장에서 특허 검색 RAG 챗봇을 혼자 만들어 임원 시연까지 갔습니다.

경력

한국전자기술연구원(KETI) — AX 연구본부 연구원 (계약직)

2026.02 - 현재

산업부 소관 전문생산기술연구소 · 폐쇄망 범용 MLOps 플랫폼 구축 (도시냉각 AI 연구 환경, 부경대 협업)

- 폐쇄망 풀스택 MLOps 플랫폼 주도적 설계·구축** — 외부 SaaS·클라우드 의존을 회피하는 자체호스팅 원칙 아래 학습·서빙·CI·실험추적/레지스트리·관측을 단일 docker-compose 스택으로 통합. Triton Inference Server · MLflow 2.18 · Gitea Actions · Prometheus + Grafana · PyTorch trainer, GPU 서버(NVIDIA L40S 46GB) 운영.
- 이종 모델 단일 Triton 동시 서빙** — 부경대 제공 3D U-Net(voxel I/O, dynamic batching)과 외부팀 PINN 3종(point I/O, 가변 N점, max_batch_size=0)을 모델별 config로 분리 설계해 한 서버에서 동시 서빙(현재 10모델 READY). 고정 shape([8,K])로 export된 외부 ONNX는 dim_param 강제로 가변 입력([N,K])으로 패치. 외부팀 모델 수용은 플랫폼의 **첫 외부 활용 사례**.
- CI 근본원인 규명 및 검증→배포 체인** — Gitea Actions checkout이 14분간 hang되는 현상을 단계별 로그로 격리, clone URL 토큰 임베드로 **14분 → 4초** 단축. 이후 ONNX 검증 → Triton 배포 → READY 폴링 → 레지스트리 메타 자동 갱신까지 있는 CI 체인 구축(수동 트리거 단계).
- 거버넌스·관측 계층** — MLflow Registry에 출처·유형 + 생애주기(received → validated → deployed → retired) 태그 컨벤션을 설계해 외부 반입 모델까지 일관 관리 (등록 모델 12개 / 버전 17개). Prometheus 15초 주기 수집 + Grafana 7패널 대시보드, Streamlit 운영 포털·Evidently 드리프트 대시보드 통합·배포(PoC).
- [자발 과제] 이미지 분류 MLOps 레일 + CCTV PoC** — 계속 남이 만든 모델을 받아 서빙했던 터라, 이번엔 카탈로그부터 학습·품질 게이트·ONNX 내보내기까지 **직접 짰습니다**. 레일과 태스크 설정을 분리해 **같은 코드로 데이터셋 3종**(CIFAR-10 · EuroSAT · 실 CCTV)을 클래스 수가 10에서 2로 바뀌어도 코드 수정 없이 통과시켰습니다. 게이트는 test 지표가 임계치에 못 미치면 **레지스트리 승격을 건너뛸니다**. 지표를 판정보다 먼저 기록해두니 차단된 런도 사유가 남습니다(승격 차단만 구현, CI 연동 미완, 차단 실사례 0건). 실데이터는 공개 교통 CCTV OpenAPI 키를 직접 신청해 확보하고 카메라 이름으로 자동 라벨링했습니다.
- 성과 지표** — 서빙 대상 모델(설계는 부경대)은 제공된 분할 압축 데이터를 통합(45-291건)한 재학습으로 **MAE 0.53 → 0.26°C · R² 0.82 → 0.95**(1차는 학습 측정 값, 주요인은 데이터 통합량 · GPU 서버 재현 시 Test MAE 0.2842 · R² 0.9473). CFD 소요시간(수십 분) 대비 Triton 추론 약 200ms, 외부 PINN 100점 22-32ms(L40S).

삼성SDI — Data Intelligence 그룹 데이터 엔지니어 인턴

2025.06 - 2025.08

삼성디지털시티(수원)

- 폐쇄망 특허 검색 RAG 챗봇 “SPA” 1인 단독 개발** — 인터넷이 완전 차단된 환경에서 Ollama + Qwen2.5-72B를 로컬 서빙하고 all-MiniLM-L6-v2 임베딩 + LangChain + FAISS(k=5)로 RAG 파이프라인 구성. 최근 5년 맥락과 직전 검색 선택지를 유지해 자동 재검색. MinIO 적재, Streamlit + Docker 배포.
- 환각 방지 라우팅 설계** — 통계·집계성 질의는 키워드 감지로 LLM을 우회해 pandas 집계·차트로 분기하는 Rule-based Agent를 설계, 수치를 LLM이 생성하지 않도록 경로 자체를 분리. 동작하는 폐쇄망 PoC로 임원 대상 시연에서 호평 수령.

프로젝트 · 연구

POSTECH 인공지능대학원 — 연구 참여 (박상돈 교수 연구실)

2026.07 - 현재

통품 할루시네이션 · selective generation, LLM 에이전트 — 언어모델이 모르는 걸 모른다고 답하게 만드는 문제를 다룹니다. THREAD(NAACL 2025)를 재현하며 매주 랩 미팅에서 발표하고, 실무에서 만든 평가·가드레일을 문헌 위에서 다시 세우는 중입니다.

JisangFolio — AI 인터랙티브 포트폴리오

2025.08 - 현재

jisangfolio.streamlit.app · 개인 프로젝트 (삼성SDI 인턴 종료 직후 자발적으로 시작)

- 이력서 기반 1인칭 AI 면접 챗봇 구축·배포 — Groq + Qwen3.6 27B, 한/영 전환, MCP 서버 자체 구현(6 tools). 프로필 지식그래프 서브그래프 검색으로 질문별 근거를 주입하고, LLM 라우터로 집계(pandas 코드 생성·실행)와 검색(FAISS dense + BM25, RRF 융합)을 분기. 인젝션·주제이탈 가드레일과 자체호스팅 LLM 오피저빌리티 구성.
- 회귀 평가 하니스** — 릴리스 간 답변 드리프트를 잡기 위해 결정적 규칙 채점을 하드 게이트로 두고, 자기채점 편향을 피해 **심사는 별도 모델**(llama-3.3-70b)로 분리. 최신 실행 **17/20 통과**(챗봇 8/9 · 라우터 6/8 · Agentic RAG 3/3, 골든셋 20건 — 벤치마크가 아닌 회귀 게이트로 운용). 가드레일·지식그래프·오피저빌리티는 pytest + GitHub Actions(Python 3.11/3.12 매트릭스, 215 테스트)로 자동 검증.

기술 스택

MLOps · 서빙 — 실무 사용·트러블슈팅 가능 · NVIDIA Triton Inference Server, MLflow(Tracking · Registry · 거버넌스), ONNX(변환 · 검증 · shape 패치), Docker / Docker Compose, Gitea Actions · GitHub Actions · pytest(CI), Prometheus, Grafana, Evidently, 폐쇄망 자체호스팅 배포, GPU 서빙(NVIDIA L40S)

AI · LLM — 가이드 없이 사용 가능 · RAG, 지식그래프 검색, 하이브리드 검색(BM25 + dense · RRF), LangChain, FAISS, Ollama(LLM 자체 서빙), LLM 라우팅, LLM-as-judge 회귀 평가, 가드레일, LLM 오피저빌리티, MCP, VLM(Qwen2.5-VL) 서빙

DATA · 언어 · Python(고급), SQL, R, Pandas, NumPy, SciPy, scikit-learn, PyTorch(학습 운영), 시계열 · 신호처리(Butterworth, FFT), Streamlit, Plotly | 기초·노출 Kubernetes, NGSI-LD, MQTT | 환경 Linux, WSL2, Git / Gitea, PromQL

학력 · 논문

University of Illinois Urbana-Champaign (UIUC) — B.S., Information Science + Data Science

편입 · 2025.12 졸업

GPA 3.89 / 4.0 · 주요 이수: CS307 Modeling & Learning, IS327 Machine Learning, IS477 Data Curation & ETL, CS277 Data Structures & Algorithms | UW Seattle — Pre-Science (GPA 3.76, Dean's List)

“Effect of Tai Chi Practice on … Perturbations While Standing in Older Adults” — *Applied Sciences* (SCIE), 2025.07

공저

본인 기여 — 연구에 사용된 압력중심(CoP) 시계열 신호처리 파이프라인 단독 설계·구현(4차 Butterworth 6Hz 센서 노이즈 필터링, Rambling/Trembling 분해, FFT 대역 적분 · NumPy/SciPy). 별도 단독저자 개인 abstract에서 사물레이션 CoP 궤적이 실측과 $r = 0.92$ ($p < 0.001$) 일치.

어학 · 병역 · 활동

어학 한국어 원어민 | 영어 상급 (TOEIC 970 · 2026.06 / OPIc IH · 2026.03) | 스페인어 기초 · **병역** 해군 병장 만기제대 (어학병 · 영어 통역, 2021.02 - 2022.10) — 제3함대·한미연합사 근무 · **활동** UIUC Korean Student Association 웹팀 (2024.08 - 2025.06)